RAPPORT PUBLIC DE PREUVE

# Banc d’essai RAG

Recherche documentaire bilingue et génération augmentée par récupération

**Un signal runtime a détecté une dégradation réelle avant que sa cause technique soit comprise.**

| 2 633 | 60 | 45 → 1 |
|---|---|---|
| passages alignés hébreu-français | générations instrumentées | alertes après correction du prompt |

Date de l’étude : 23 août 2026

Version publique : 20 septembre 2026

Instrumentation : NeoMundi Continuous Control Launcher

Publication autorisée par le porteur du projet Kabbalah App. Cette version publique exclut les questions brutes, les données personnelles, les détails de sécurité exploitables et les éléments d’intégration réservés.

# 1. Synthèse exécutive

Le banc d’essai devait sélectionner une architecture de recherche documentaire et un modèle de génération pour un corpus kabbalistique bilingue hébreu-français. Les seuils de décision ont été fixés avant la mesure.

| Volet | Résultat principal | Lecture |
|---|---|---|
| Recherche documentaire | voyage-4-large : rappel de référence à 0,962 | Avance de 7,7 points sur le deuxième candidat dans le protocole principal. |
| Génération | Mistral Large 3 : 24 victoires sur 30 | Résultat à confirmer après contrôle de l’effet de longueur des réponses. |
| Signal NeoMundi | 45/60 alertes puis 1/60 après correction | La dégradation provenait d’un prompt contradictoire et de variables non substituées. |

**Ce que cette étude établit : la mesure runtime peut révéler une dégradation effective pendant une évaluation RAG, sans se substituer aux métriques métier ni décider quel fournisseur doit être retenu.**

## Découverte structurante

L’analyse agrégée de 109 requêtes utilisateurs a montré que seule une minorité portait sur le corpus doctrinal effectivement indexé. Une grande partie des besoins concernait des données calculées ou des contenus absents de l’index. L’amélioration du retrieval ne peut pas compenser un périmètre documentaire incomplet.

Aucune question utilisateur brute n’est reproduite dans ce rapport public.

# 2. Protocole

Le retrieval et la génération ont été évalués séparément. La génération n’a été testée qu’après sélection du moteur de recherche documentaire, afin d’éviter de noter des réponses alimentées par des passages non pertinents.

## Corpus

- 2 633 passages alignés hébreu-français : Sefer Yetzirah, Tomer Devorah et Tehillim.
- Chaque passage a été indexé dans les deux langues, soit 5 266 vecteurs par modèle candidat.

## Jeu d’évaluation

- 99 questions synthétiques difficiles, dont 78 à réponse unique.
- Recouvrement lexical contrôlé : médiane nulle ; 63 questions sur 99 sans mot significatif repris de leur passage source.
- 7 questions réelles anonymisées utilisées uniquement comme témoin, jamais comme base statistique principale.

## Métriques de retrieval

| Métrique | Définition opérationnelle |
|---|---|
| Rappel@5 / Rappel@10 | Présence du passage attendu parmi les 5 ou 10 premiers résultats. |
| MRR@10 | Rang moyen du premier résultat pertinent, pondéré par l’inverse du rang. |
| Témoin | Contrôle limité destiné à détecter un éventuel écart majeur entre questions synthétiques et réelles. |

## Évaluation de génération

- 30 questions ; contexte de retrieval identique pour les deux candidats.
- Ordre de présentation randomisé et évaluation à l’aveugle.
- Les passages réellement retrouvés ont été transmis, sans corriger a posteriori les erreurs du moteur.

# 3. Résultats de recherche documentaire

| Candidat | Réf. R@10 | R@5 | R@10 | MRR@10 | Témoin |
|---|---|---|---|---|---|
| voyage-4-large | 0,962 | 0,919 | 0,950 | 0,847 | 1,000 |
| Qwen3-Embedding-8B | 0,885 | 0,768 | 0,879 | 0,682 | 0,714 |
| bge-m3 | 0,538 | 0,414 | 0,535 | 0,298 | 0,714 |
| bge-multilingual-gemma2 | 0,295 | 0,232 | 0,313 | 0,146 | 0,429 |
| gemini-embedding-2 | Non mesuré | - | - | - | Quota |

Le seuil de faisabilité fixé à 0,70 est dépassé. Le découpage en passages alignés est donc exploitable dans ce protocole. voyage-4-large devance Qwen3-Embedding-8B de 7,7 points sur le rappel de référence.

## Effet de la langue

| Modèle | Français seul | Hébreu seul | Deux langues |
|---|---|---|---|
| Qwen3-Embedding-8B | 0,872 | 0,731 | 0,885 |
| bge-multilingual-gemma2 | 0,282 | 0,436 | 0,295 |
| bge-m3 | 0,538 | 0,346 | 0,538 |

Une requête française retrouve le passage via sa version hébraïque seule dans 73 % des cas avec Qwen3-Embedding-8B. Toutefois, l’indexation bilingue n’améliore pas uniformément tous les modèles : elle peut même dégrader certains classements. La stratégie d’indexation doit donc être mesurée par modèle et par corpus.

# 4. Résultats de génération

| 24 | 5 | 1 |
|---|---|---|
| victoires Mistral Large 3 | victoires Claude Sonnet 4.6 | égalité |

La comparaison a été conduite sur 30 paires de réponses, avec le même contexte de retrieval et une notation à l’aveugle. Aucun biais de position n’a été observé dans la répartition des votes.

## Réserve principale

Mistral a produit des réponses en moyenne 37 % plus longues et a été le modèle le plus long dans 27 paires sur 30. La qualité perçue et la longueur sont donc fortement corrélées dans cette expérience. Le résultat ne permet pas d’isoler proprement l’effet du modèle de celui du format de réponse.

**Décision prudente : vérifier d’abord l’hypothèse de longueur avec une manche complémentaire avant toute migration de fournisseur.**

## Incident de protocole détecté

Une première manche avait produit un résultat extrême. Elle a été invalidée après découverte de deux jeux d’instructions contradictoires dans le prompt assemblé et de variables de gabarit non remplacées. Le générateur a ensuite reçu des garde-fous bloquants et des tests unitaires dédiés.

Cette manche invalidée n’est pas utilisée pour comparer les modèles. Elle constitue en revanche le cas principal pour évaluer l’utilité du signal runtime NeoMundi.

# 5. Preuve apportée par NeoMundi

Le Continuous Control Launcher a instrumenté 60 appels de génération lors de la manche concernée. Avant que la cause soit comprise, le signal avait déjà révélé une dégradation anormale.

| Manche | Alertes d’hallucination | Stabilité moyenne | Diagnostic |
|---|---|---|---|
| v1 - prompt contradictoire | 45 / 60 | 0,68 à 0,77 | Dégradation réelle, manche invalidée |
| v2 - prompt corrigé | 1 / 60 | 0,915 à 0,923 | Retour à un comportement nettement plus stable |

**Le signal a précédé le diagnostic : il a rendu visible un problème réel que l’analyse humaine n’avait pas encore identifié.**

## Frontière d’interprétation

- NeoMundi n’a pas désigné le meilleur modèle de retrieval ou de génération.
- Les métriques métier, la notation à l’aveugle et les contraintes de souveraineté restent externes à NeoMundi.
- Le signal runtime constitue une variable complémentaire pour repérer, documenter et investiguer une dégradation.
- Un composant d’évaluation appartenait à une famille de modèles incluse dans la comparaison ; ce signal ne doit donc pas servir seul à arbitrer entre fournisseurs.

L’étude a aussi révélé des contraintes d’intégration concernant les prompts longs et la latence. Les détails de sécurité et d’implémentation ont été retirés de cette version publique et traités séparément.

# 6. Couverture des besoins réels

L’analyse agrégée des journaux a porté sur 109 requêtes autonomes. Elle met en évidence une limite plus importante que le choix du moteur : la majorité des besoins utilisateurs vise des informations qui ne sont pas présentes dans le corpus indexé.

| Catégorie agrégée | Nombre | Accessible dans le corpus actuel ? |
|---|---|---|
| Doctrine | 8 | Oui |
| Profil calculé | 27 | Non - donnée calculée |
| Astrologie | 24 | Non - hors corpus |
| Hors sujet | 20 | Non |
| Conversation courante | 2 | Sans objet |
| Relances dépendantes | 28 | Non évaluables isolément |

Ces agrégats sont publiés sans contenu de requête, identifiant, profil individuel ni donnée personnelle.

## Recommandations

- Tester l’effet d’une consigne de longueur harmonisée avant de changer de modèle de génération.
- Arbitrer explicitement performance, souveraineté et traitement des données sensibles avant le choix du moteur d’embeddings.
- Étendre l’index aux contenus réellement demandés lorsque cela est juridiquement et techniquement approprié.
- Rejouer le candidat non mesuré uniquement si son résultat peut réellement changer la décision.

# 7. Limites et reproductibilité

## Limites de l’étude

- Le témoin réel ne contient que 7 questions et ne constitue pas une base statistique autonome.
- La comparaison de génération confond partiellement longueur et qualité perçue.
- Un candidat d’embeddings n’a pas pu être mesuré en raison d’une limite fournisseur.
- Les résultats sont propres au corpus, aux questions, aux versions de modèles et aux conditions de mesure du 23 août 2026.
- Les signaux NeoMundi ne remplacent ni une vérité terrain métier, ni une évaluation humaine, ni une décision de gouvernance.

## Reproductibilité

- Harnais et résultats versionnés.
- 28 tests unitaires couvrant le corpus, les métriques, le recouvrement lexical et l’assemblage du prompt.
- Rapport généré depuis les fichiers de résultats, sans saisie manuelle des chiffres principaux.
- Questions réelles, correspondances de l’évaluation à l’aveugle et notes conservées hors du périmètre public.

## Périmètre de publication

Cette version publique conserve les résultats vérifiables et les limites nécessaires à leur interprétation. Elle exclut les questions utilisateurs, les données personnelles, les secrets, les extraits de code sensibles, les chemins d’infrastructure et les détails susceptibles d’accroître le risque opérationnel.

**Claim admissible : dans ce banc d’essai RAG, le signal runtime NeoMundi a détecté une dégradation réelle avant que sa cause technique soit identifiée, puis a reflété le retour à un comportement plus stable après correction.**

NeoMundi apporte le signal. L’application, ses experts et ses règles de décision transforment ce signal en valeur.